## 딥러닝/클라우드

Speed up inference

오세종 MIT DANKOOK UNIVERSITY

## **Contents**

- 1. Text Generation Interface
- 2. vLLM
- 3. Speed up methods

## **Summary**

- LLM의 문제
  - 질의에 대한 response time 이 길다.
  - Realtime application 개발시 문제
- Speed up inference
  - Text Generation Interface(tgi) :
    - Huggingface document (link)
    - medium.com document (link)
  - vLLM : <a href="https://github.com/vllm-project/vllm">https://github.com/vllm-project/vllm</a>
- Speed up methods:
  - Document (<u>link</u>)

### 1. Text Generation Interface



- Developed by hugging face
- Text Generation Inference (TGI) is a toolkit for deploying and serving Large Language Models (LLMs).
- TGI enables high-performance text generation for the most popular opensource LLMs, including Llama, Phi3, gemma, Mistral, BLOOM, GPT-NeoX, and T5.
- Text Generation Inference implements many optimizations and features.
- Text Generation Inference is used in production by multiple projects, such as
  - <u>Hugging Chat</u>, an open-source interface for open-access models, such as Open Assistant and Llama
  - OpenAssistant, an open-source community effort to train LLMs in the open
  - <u>nat.dev</u>, a playground to explore and compare LLMs.
- Supported GPU: Nividia GPU (link), AMD GPU (link), Intel GPU (link), Gaudi, Inferentia

#### 1. Text Generation Interface

Setup : TGI on an Nvidia GPU

```
model=teknium/OpenHermes-2.5-Mistral-7B

volume=$PWD/data # share a volume with the Docker container to avo

docker run --gpus all --shm-size 1g -p 8080:80 -v $volume:/data \
    ghcr.io/huggingface/text-generation-inference:2.4.1 \
    --model-id $model
```

#### inference

- https://docs.vllm.ai/en/latest/
  - PagedAttention 등의 기법을 활용하여 문장 생성 속도를 비약적으로 높임
  - 허깅페이스 대비 최대 24배까지 성능을 높일 수 있다고 알려짐



- vLLM is fast with:
  - State-of-the-art serving throughput
  - Efficient management of attention key and value memory with PagedAttention
  - Continuous batching of incoming requests
  - Fast model execution with CUDA/HIP graph
  - Quantization: GPTQ, AWQ, INT4, INT8, and FP8
  - Optimized CUDA kernels, including integration with FlashAttention and FlashInfer.
  - Speculative decoding
  - Chunked prefill
  - OpenAI-compatible API server
  - Support NVIDIA GPUs, AMD CPUs and GPUs, Intel CPUs, Gaudi® accelerators and GPUs, PowerPC CPUs, TPU, and AWS Trainium and Inferentia Accelerators.


- 지원 모델
  - https://docs.vllm.ai/en/latest/models/supported\_models.html

#### **Text Generation**

Architecture	Models	Example HF Models	<u>LoRA</u>	<u>PP</u>
AquilaForCausalLM	Aquila, Aquila2	BAAI/Aquila-7B, BAAI/AquilaChat-7B, etc.	<u>~</u>	<u>~</u>
ArcticForCausalLM	Arctic	Snowflake/snowflake-arctic-base, Snowflake/snowflake-arctic-instruct, etc.		<b>✓</b>
BaiChuanForCausalLM	Baichuan2, Baichuan	baichuan-inc/Baichuan2-13B-Chat, baichuan-inc/Baichuan-7B, etc.	<u>~</u>	<u>~</u>
BloomForCausalLM	BLOOM, BLOOMZ, BLOOMChat	bigscience/bloom, bigscience/bloomz, etc.		<u>~</u>
BartForConditionalGeneration	BART	<pre>facebook/bart-base, facebook/bart-large-cnn, etc.</pre>		

 For other models, you can check the config.json file inside the model repository. If the "architectures" field contains a model architecture listed below, then it should be supported in theory.

- 지원 모델
  - 다운로드한 HuggingFaceTB/SmolLM2-360M-Instruct 모델을 vllm 이 지원 하는지 확인



- Installation
  - 기본적으로 linux OS만 지원
  - Window 에서 사용시에는 WSL 환경에서 사용할 수 있음
  - Vs code 는 WSL 과 쉽게 연동됨

- Install GPU version (cuda)
  - https://docs.vllm.ai/en/latest/getting\_started/installation.html

vLLM is a Python library that also contains pre-compiled C++ and CUDA (12.1) binaries.

### Requirements #

- OS: Linux
- Python: 3.9 3.12
- GPU: compute capability 7.0 or higher (e.g., V100, T4, RTX20xx, A100, L4, H100, etc.)

```
# (Recommended) Create a new conda environment.
conda create -n myenv python=3.10 -y
conda activate myenv

# Install vLLM with CUDA 12.1.
pip install vllm
```


- Install CPU version
  - https://docs.vllm.ai/en/latest/getting\_started/cpu-installation.html
  - Requirement:
    - OS: Linux
    - Compiler: gcc/g++>=12.3.0 (optional, recommended)
    - Instruction set architecture (ISA) requirement: AVX512 (optional, recommended)


```
sudo apt-get update -y
sudo apt-get install -y gcc-12 g++-12 libnuma-dev
sudo update-alternatives --install /usr/bin/gcc gcc
/usr/bin/gcc-12 10 --slave /usr/bin/g++ g++ /usr/bin/g++-12

pip install --upgrade pip
pip install cmake>=3.26 wheel packaging ninja "setuptools-scm>=8" numpy
pip install -v -r requirements-cpu.txt --extra-index-url
https://download.pytorch.org/whl/cpu

VLLM_TARGET_DEVICE=cpu python setup.py install
```

- vLLM with colab
  - 사전에 GPU 를 사용하도록 설정







Text generation example (1)

20\_vllm\_text\_generation\_1.py

```
!pip install vllm
!pip install triton
from vllm import LLM, SamplingParams
model = LLM(model="facebook/opt-125m")
sampling params = SamplingParams(temperature=0.8, top p=0.95)
prompts = [
  "The future of AI is",
outputs = model.generate(prompts, sampling params)
answer = outputs[0].outputs[0].text
print(answer)
```

```
Processed prompts: 100%| | 1/1 [00:00<00:00, 7.12it/s, est. speed input: 43.14 toks/s, output: 115.02 toks/s] cloud computing

A recent report by Arvind Kejriwal suggests Al will be on
```

Text generation example (2)

18\_vllm\_text\_generation\_2.py

```
!pip install vllm
!pip install triton
from vllm import LLM, SamplingParams
model = LLM(model="microsoft/Phi-3-mini-4k-instruct", dtype="float16")
sampling_params = SamplingParams(temperature=0.8, top p=0.95,
                                 max tokens=500)
prompts = [
  "show me python example for histogram chart",
outputs = model.generate(prompts, sampling_params)
answer = outputs[0].outputs[0].text
print(answer)
```

```
[10] outputs = model.generate(prompts, sampling_params)
    answer = outputs[0].outputs[0].text
    print(answer)
```python
    import numpy as np
    import matplotlib.pyplot as plt
    # Assuming 'data' is a dictionary containing 'distance' and 'frequency'
    data = {
        'distance': np.arrav([10, 20, 30, np.nan, 40, 50]), # Example data with NaN
        'frequency': np.array([5, 10, 15, np.nan, 20, 25])
    # Filter out NaN values
    mask = ~np.isnan(data['distance']) & ~np.isnan(data['frequency'])
    filtered_distance = data['distance'][mask]
    filtered_frequency = data['frequency'][mask]
    # Plotting the histogram
    plt.hist(filtered_distance, bins=5, range=(10, 50), color='blue', edgecolor='black', weights=filtered_frequency)
    plt.title('Histogram of Distances')
    plt.xlabel('Distance')
    plt.ylabel('Frequency')
    # Set y-axis limit
    plt.ylim(0, 30)
    plt.show()
    This code snippet will create a histogram that ignores any NaN values and limits the y-axis from 0 to 30. Is there
```

- Note. Colab에 영구적으로 패키지 설치하기
  - 새로운 세션을 시작하거나 런타임을 초기화하는 경우 패키지 설치를 반복적 으로 수행해야한다는 번거로움
  - https://dacon.io/codeshare/4200

```
import os, sys
from google.colab import drive
drive.mount('/content/drive')
my_path = '/content/package'
save path = '/content/drive/MyDrive/Colab Notebooks/package' ## 패키지가
저장될 경로
os.symlink(save path, my path)
sys.path.insert(0, my_path)
```

!pip install --target=\$my path selenium


○ 영구 설치한 package import 하기

```
import os, sys
from google.colab import drive
drive.mount('/content/drive')


my_path = '/content/package'
save_path = '/content/drive/MyDrive/Colab Notebooks/package'

os.symlink(save_path, my_path)
sys.path.insert(0, my_path)
import selenium
```

- Tensor Parallelism
  - weights, gradient 그리고 optimizer 상태와 같은 텐서를 여러 chunk로 분산 하여 다중 GPU 장비에서 분산 저장하고 처리



Reference: Transformers — Efficient Training on Multiple GPUs



#### Quantization(양자화)

- 실수형 변수를 정수형 변수로 변환하는 과정
- 주로 딥러닝에서 FP32(32-bit floating point)는 사용하여 가중치를 표현하는데, 이를 FP16(16-bit floating point)이나 INT8(8-bit integer)로 변환하여 모델의 크기를 줄일 수 있게 된다.


#### Bitsandbytes

• QLoRA를 논문으로 발표한 Tim Dettmers에 의해 배포된 양자화 라이브러리

#### GPTQ

- LLM을 양자화하는 또다른 방법
- Post-Training Quantization(PTQ)를 통해 32비트에서 3~4비트로 정수 양자화를 수행
- 양자화는 추론시에만 적용 (학습시에는 X)

- Optimized transformers code for inference using flash-attention
  - Flash Attention은 Google Research Brain 팀에 의해서 개발된 메커니즘
  - N을 시퀀스 길이라고 할 때, 전통적인 Attention은 O(N²)의 메모리 복잡성
  - 이로 인해 모델의 효율과 속도가 떨어지는 문제가 발생.
  - Flash Attention은 메모리 복잡성을 선형 복잡도인 O(N)까지 줄임.
  - 이를 통해 훈련과 추론 속도를 가속화
  - 다른 최적화 기법과는 달리, Flash Attention은 하드웨어적으로 성능을 개선
    - GPU 내 메모리 계층에 따라 용량과 속도가 다르다는 것에서 착안



- Precision reduction
  - PyTorch는 32-bit floats를 디폴트로 사용
  - 이를 float16 or bfloat16로 변환하여 사용
  - 모델을 20%까지 빠르게 해주고, 메모리 소비를 2배 줄이는 효과

float 32



Sign (1 bit) Exponent (8 bits)

Fraction (23 bits)

float 16 ("half" precision)




Sign (1 bit) Exponent (5 bits)

Fraction (10 bits)

https://lightning.ai/pages/community/ tutorial/accelerating-large-languagemodels-with-mixed-precisiontechniques/

- Mixed-precision training
  - 학습 동안에, 계속 16-bit을 쓰지 않고 필요에 따라 16-32를 왔다갔다함.
  - 이렇게 하면 accuracy와 stability를 유지하면서 학습이 가능


- Pruning
  - 모델 학습 시 중요한 파라미터(결과에 유의미한 영향을 끼치는)는 살리고 아 닌건 가지치기하는 경량화 방법.
  - Pruning은 추론속도를 높여주고(아예 파라미터가 줄어들기 때문에), 모델의 복잡도를 줄여서 Robust하게 만들어준다.
  - 원하는 정도만큼 prune이 가능 (50%까지)
  - https://arxiv.org/pdf/2305.11627



- Batch inference
  - https://dytis.tistory.com/59
  - ML training 에서의 batch 와 유사 개념
  - Inference 에서의 batch : 모델이 동시에 처리하는 입력 데이터의 묶음
  - 여러 입력을 한번에 모델에 전달하여 병렬처리 -> 성능향상
  - 여러 종류의 batch inference 방법이 존재

#### Kernel fusion

- GPU는 주로 다양한 수학적 연산, 예를 들면 MatMul, Softmax, BatchNorm 등을 수행
- GPU에서 연산이 실행되면, 필요한 데이터를 메모리로 불러와 연산을 수행한 후, 결과를 다시 메모리에 저장
- kernel fusion은 기본적으로 연속된 독립적인 계산 작업들을 단일 하드웨어 작업으로 통합
- 결과적으로 여러 독립적인 계산을 하나로 통합하여 메모리 이동을 최소화



FlashAttention에서 제공하는 fused Kernel의 성능 향상을 시각적으로 보여줌

https://github.com/Dao-AlLab/flash-